

École Marocaine des Sciences de l'Ingénieur

Filière : Ingénierie Informatique et Réseau option : Intelligence Artificielle
& Sciences des Données

Projet de Fin de Module

**Prétraitement, Représentation, Modélisation
et Analyse des Données avec scikit-learn**

Module :

Exploration des données

Encadrée par :

Pr. Intissar SALHI

Réalisé par :

Rania BIKIKRE

Année universitaire 2025-2026

Résumé

Ce rapport présente une chaîne complète de traitement de données construite dans le cadre du projet de fin de module. Deux parties complémentaires sont développées : une étude sur données tabulaires utilisant le dataset *Titanic* (891 instances, 15 attributs), et une étude sur données textuelles exploitant le corpus *20 Newsgroups* (4 catégories retenues).

La première partie couvre l'inspection rigoureuse du dataset, la stratégie de pré-traitement justifiée pour chaque type de variable, la construction d'un **ColumnTransformer** multi-flux et de pipelines complets, la comparaison de trois modèles de classification avec optimisation par **GridSearchCV**, et l'évaluation par validation croisée, matrice de confusion et courbe ROC.

La seconde partie compare trois représentations vectorielles (Bag of Words, TF-IDF, TF-IDF bigrammes), analyse un paradoxe de performance observé, et inspecte les coefficients du modèle final pour identifier les mots discriminants par catégorie. Toutes les sorties expérimentales sont documentées et analysées.

Mots-clés : prétraitement, imputation, encodage, normalisation, Pipeline, ColumnTransformer, classification supervisée, TF-IDF, n-grammes, validation croisée, data leakage, AUC-ROC.

0 Table des matières

1	Introduction	4
2	Présentation des jeux de données	5
2.1	Dataset Titanic	5
2.1.1	Inventaire complet des 15 colonnes	5
2.1.2	Valeurs manquantes dans les features retenues	6
2.2	Corpus 20 Newsgroups	6
3	Partie I — Données tabulaires : Dataset Titanic	7
3.1	Inspection initiale et sorties expérimentales	7
3.1.1	Figure 1 — Analyse des valeurs manquantes	7
3.1.2	Figure 2 — Distribution de la variable cible et analyse par sexe	8
3.1.3	Figure 3 — Distributions des variables numériques	9
3.1.4	Figure 4 — Distribution des variables catégorielles	10
3.1.5	Figure 5 — Matrice de corrélation	11
3.2	Stratégie de prétraitement	12
3.2.1	Principe de prévention du data leakage	12
3.2.2	Architecture du ColumnTransformer	12
3.3	Résultats expérimentaux	12
3.3.1	Figure 6 — Comparaison des modèles par validation croisée	13
3.3.2	Figure 7— Évaluation finale du modèle optimisé	14
4	Partie II — Données textuelles : 20 Newsgroups	16
4.1	Représentations vectorielles	16
4.1.1	Pourquoi les matrices textuelles sont creuses	16
4.2	Résultats expérimentaux	16
4.2.1	Figure 8 — Matrice de confusion et comparaison des pipelines	17
4.2.2	Figure 9 — Mots discriminants par catégorie	18
5	Discussion critique	20
5.1	Apports méthodologiques	20
5.2	Limites	20
5.3	Prolongements possibles	20
6	Conclusion	21
	Références	22
A	Annexe A — Liste des figures et leur signification	23

0 Table des figures

1	Pourcentage de valeurs manquantes par colonne dans le dataset Titanic brut.	7
2	Distribution de la variable cible <code>survived</code> (gauche) et répartition par sexe (droite).	8
3	Histogrammes (ligne du haut) et boxplots (ligne du bas) des 4 variables numériques. La ligne rouge en pointillé indique la médiane.	9
4	Distribution des variables catégorielles : sex, class, embarked, who, deck. Le pourcentage de valeurs manquantes est indiqué en rouge sous chaque graphique.	10
5	Matrice de corrélation de Pearson entre les variables numériques. Bleu = corrélation négative, rouge = corrélation positive, blanc = absence de corrélation linéaire.	11
6	Boxplots des scores de validation croisée (5-fold) pour les 3 modèles. Chaque boîte représente la distribution des 5 scores ; la valeur centrale est annotée.	13
7	Évaluation du Random Forest optimisé : matrice de confusion (gauche), courbe ROC (centre), importance des features (droite).	14
8	Gauche : matrice de confusion du pipeline B (TF-IDF + NaiveBayes). Droite : comparaison des 3 pipelines textuels.	17
9	Top 15 mots les plus discriminants par catégorie selon les coefficients de la Régression Logistique (Pipeline C, TF-IDF bigrammes). Un coefficient élevé indique que ce mot pousse fortement vers la prédiction de la catégorie correspondante.	18

1 Introduction

Le prétraitement des données représente entre 60 et 80% du temps d'un projet de Machine Learning selon les estimations industrielles. Un prétraitement mal conçu — même associé à un modèle sophistiqué — conduit à des résultats biaisés ou à des évaluations trop optimistes dues à des fuites de données (*data leakage*).

Ce projet vise à démontrer la maîtrise d'une chaîne complète de traitement : inspection des données, justification des choix de prétraitement, construction de pipelines robustes, comparaison expérimentale de modèles, et interprétation critique des résultats — y compris les résultats contre-intuitifs.

2 Présentation des jeux de données

2.1 Dataset Titanic

Le dataset *Titanic* contient des informations sur 891 passagers du RMS Titanic (nauffrage du 15 avril 1912). La tâche est une **classification binaire supervisée** : prédire la survie (`survived` = 0 ou 1).

2.1.1 Inventaire complet des 15 colonnes

TABLE 1 – Inventaire et décisions pour les 15 colonnes du dataset Titanic

Variable	Type	Nature	Description	Décision
<code>survived</code>	int64	Binaire	Survie (1) ou décès (0)	Cible y
<code>pclass</code>	int64	Ordinale	Classe de voyage (1, 2, 3)	Retenue
<code>sex</code>	object	Nominale	Sexe : male / female	Retenue
<code>age</code>	float64	Continue	Âge en années	Retenue
<code>sibsp</code>	int64	Discrète	Frères/sœurs/conjoints à bord	Retenue
<code>parch</code>	int64	Discrète	Parents/enfants à bord	Retenue
<code>fare</code>	float64	Continue	Tarif du billet (£)	Retenue
<code>embarked</code>	object	Nominale	Port d'embarquement (C/Q/S)	Retenue
<code>class</code>	category	Ordinale	Version textuelle de <code>pclass</code>	Supprimée (doublon)
<code>who</code>	object	Nominale	man / woman / child	Supprimée (redondante)
<code>adult_male</code>	bool	Binaire	Adulte masculin	Supprimée (dérivée)
<code>deck</code>	category	Nominale	Pont (A–G)	Supprimée (77.2% NaN)
<code>embark_town</code>	object	Nominale	Ville d'embarquement	Supprimée (doublon)
<code>alive</code>	object	—	yes / no	Fuite directe !
<code>alone</code>	bool	Binaire	Voyage en solo	Supprimée (dérivée)

Fuite de données directe — Colonne `alive`

La colonne `alive` encode exactement la variable cible `survived` sous forme textuelle (“yes”/“no”). Son inclusion dans le modèle conduirait à une accuracy artificielle de 100%. Elle constitue un cas de *direct leakage* et doit être supprimée avant tout traitement.

2.1.2 Valeurs manquantes dans les features retenues

TABLE 2 – Valeurs manquantes et stratégie d'imputation

Colonne	Manquants	Pourcentage	Stratégie retenue
age	177	19.9%	Médiane (robuste aux outliers)
embarked	2	0.2%	Mode (valeur la plus fréquente)
fare	0	0%	Aucune
Autres retenues	0	0%	Aucune

2.2 Corpus 20 Newsgroups

Le corpus *20 Newsgroups* contient environ 18 000 articles de forums organisés en 20 catégories. Quatre catégories thématiquement distinctes ont été retenues : `rec.sport.baseball`, `sci.space`, `talk.politics.guns`, `comp.graphics`.

Le paramètre `remove=('headers', 'footers', 'quotes')` supprime les métadonnées pour éviter que le modèle apprenne des adresses email plutôt que du contenu thématique — une forme de *data leakage* contextuel.

3 Partie I — Données tabulaires : Dataset Titanic

3.1 Inspection initiale et sorties expérimentales

3.1.1 Figure 1 — Analyse des valeurs manquantes




FIGURE 1 – Pourcentage de valeurs manquantes par colonne dans le dataset Titanic brut.

Analyse critique des résultats

La Figure 1 révèle trois niveaux de problèmes distincts.

Cas critique — deck (77.2%) : Presque 8 passagers sur 10 n'ont pas de pont renseigné. Imputer 688 valeurs sur 891 reviendrait à inventer les données. La suppression s'impose sans ambiguïté : on ne peut pas tirer d'information fiable d'une colonne aussi incomplète. Garder cette colonne constituerait une erreur méthodologique grave.

Cas modéré — age (19.9%) : Un passager sur cinq n'a pas d'âge renseigné. Cette colonne est néanmoins précieuse (les enfants étaient prioritaires à l'évacuation). On la conserve et on impute par la **médiane**. La médiane est préférée à la moyenne car la distribution d'âge est légèrement asymétrique et la présence d'outliers (très jeunes enfants) perturberait la moyenne.

Cas négligeable — embarked (0.2%) : Seulement 2 valeurs manquantes. Imputation par le **mode** (valeur la plus fréquente = Southampton, S) — choix trivial et sans impact mesurable sur les performances.

La ligne de référence à 40% confirme que seule **deck** mérite suppression. En deçà de ce seuil, une imputation est préférable à la perte d'information.

3.1.2 Figure 2 — Distribution de la variable cible et analyse par sexe




FIGURE 2 – Distribution de la variable cible `survived` (gauche) et répartition par sexe (droite).

Analyse critique des résultats

Graphique gauche — Déséquilibre de classes modéré. La variable cible présente 549 décédés (61.6%) contre 342 survivants (38.4%). Ce déséquilibre est modéré : un modèle naïf qui prédirait toujours “décédé” atteindrait 61.6% d’accuracy sans aucun apprentissage. Ce contexte justifie l’utilisation de l’AUC-ROC en complément de l’accuracy pour évaluer les modèles.

Graphique droit — Sexe comme facteur dominant. La disparité est frappante : 81 femmes décédées contre 233 survivantes (taux de survie féminin $\approx 74\%$), versus 468 hommes décédés contre seulement 109 survivants (taux de survie masculin $\approx 19\%$). Cette asymétrie historique (protocole “femmes et enfants d’abord”) sera confirmée comme premier facteur discriminant dans l’importance des features du Random Forest (Figure 7).

3.1.3 Figure 3 — Distributions des variables numériques




FIGURE 3 — Histogrammes (ligne du haut) et boxplots (ligne du bas) des 4 variables numériques. La ligne rouge en pointillé indique la médiane.

Analyse critique des résultats

Variable age (colonne 1) : distribution approximativement normale centrée autour de 28 ans (médiane). Quelques valeurs très jeunes (nourrissons) et très âgées (70+ ans), mais pas d'outliers extrêmes. Le boxplot confirme des moustaches raisonnables. **StandardScaler** est adapté pour cette variable.

Variable fare (colonne 2) : distribution **fortement asymétrique à droite**. L'histogramme montre que la majorité des passagers a payé moins de 50£, mais le boxplot révèle des outliers significatifs atteignant 512£ (passagers de 1ère classe en cabine de luxe). La médiane (≈ 14 £) est bien inférieure à la moyenne (≈ 32 £), confirmant la distorsion. C'est pourquoi on impute par la **médiane** (robuste) et non par la moyenne. Alternativement, un **RobustScaler** aurait été plus approprié que le **StandardScaler** pour cette variable spécifiquement.

Variables sibsp et parch (colonnes 3–4) : distributions très concentrées en 0 (la majorité voyage seule ou sans enfants). Les boxplots montrent de nombreux points outliers, mais leur plage de variation est faible. Le scaling a peu d'impact sur ces variables discrètes à faible variance.

Conclusion pour le choix du scaler : la présence d'outliers dans **fare** justifie le choix du **StandardScaler** (moins sensible que le **MinMaxScaler**) et confirme le rejet du **MinMaxScaler** qui compresserait toutes les autres valeurs vers 0 à cause de ce maximum à 512£.

3.1.4 Figure 4 — Distribution des variables catégorielles




FIGURE 4 – Distribution des variables catégorielles : sex, class, embarked, who, deck. Le pourcentage de valeurs manquantes est indiqué en rouge sous chaque graphique.

Analyse critique des résultats

La Figure 4 complète l’exploration en présentant les 5 variables catégorielles du dataset.

Variable sex : la distribution est relativement équilibrée (environ 65% d’hommes, 35% de femmes), sans valeurs manquantes. Cette variable sera encodée en One-Hot Encoding (`sex_male` = 0 ou 1).

Variable class : répartition en trois modalités (First, Second, Third), directement redondante avec `pclass` — c’est pour cette raison qu’elle est supprimée avant la modélisation.

Variable embarked : trois ports d’embarquement, Southampton (S) très majoritaire ($\approx 72\%$), suivi de Cherbourg (C) et Queenstown (Q). Seulement 2 valeurs manquantes, imputées par le mode (S).

Variable who : trois modalités (man, woman, child) — dérivée directement de `sex` et `age`. Sa suppression est justifiée par la redondance totale avec des variables déjà retenues.

Variable deck : la mention “77.1% manquants” apparaît en rouge sous le graphique, confirmant visuellement la décision de suppression. La distribution des ponts existants (C, B, D, E...) est très fragmentée, ce qui rendrait l’imputation encore moins fiable.

3.1.5 Figure 5 — Matrice de corrélation




FIGURE 5 — Matrice de corrélation de Pearson entre les variables numériques. Bleu = corrélation négative, rouge = corrélation positive, blanc = absence de corrélation linéaire.

Analyse critique des résultats

La matrice de corrélation (Figure 5) révèle plusieurs relations importantes :

pclass ↔ **survived** ($r = -0.34$) : corrélation négative modérée. Plus la classe est élevée (numériquement : 1, 2, 3), moins le taux de survie est élevé. Autrement dit, les passagers de 1ère classe (pclass=1) survivent significativement plus que ceux de 3ème classe (pclass=3). Cette relation est attendue historiquement — les canots de sauvetage étaient plus accessibles depuis les ponts supérieurs.

fare ↔ **survived** ($r = +0.26$) : corrélation positive faible. Un tarif plus élevé est associé à une meilleure survie. C'est cohérent avec **pclass** : les passagers riches (tarif élevé) voyagent en 1ère classe et survivent plus.

fare ↔ **pclass** ($r = -0.55$) : corrélation négative forte, attendue (1ère classe = tarifs plus élevés). Cette corrélation entre features n'est pas problématique ici car nous utilisons un Random Forest qui gère naturellement la multicollinéarité.

sibsp ↔ **parch** ($r = +0.41$) : corrélation modérée — les familles nombreuses voyagent ensemble (plus d'enfants = plus de parents). Ces deux variables apportent une information partiellement redondante.

Absence de corrélations dangereusement élevées : aucune paire de features

retenues ne dépasse $|r| = 0.6$, ce qui indique que la multicolinéarité n'est pas un problème critique pour ce dataset.

3.2 Stratégie de prétraitement

3.2.1 Principe de prévention du data leakage

Point de vigilance

Le split train/test est effectué **avant** tout prétraitement. Le `SimpleImputer` et le `StandardScaler` apprennent leurs paramètres (`.fit()`) **uniquement** sur le train set, puis les appliquent (`.transform()`) au test set. L'encapsulation dans un `Pipeline` garantit cette contrainte automatiquement lors de la validation croisée.

3.2.2 Architecture du `ColumnTransformer`

TABLE 3 – Structure du `ColumnTransformer` — 3 flux parallèles

Flux	Colonnes	Imputation	Transformation	Features sorties
num	age, fare, sibsp, parch	Médiane	StandardScaler	4
nom	sex, embarked	Mode	OneHotEncoder (drop=first)	3
ord	pclass	Mode	OrdinalEncoder	1
Total après transformation :				8

Justification méthodologique

Médiane pour les numériques : fare présente des outliers à 512£ ; la médiane y est robuste. **OneHotEncoder (drop='first')** pour les nominales : évite la multicolinéarité parfaite (`sex_male + sex_female = 1` toujours). **OrdinalEncoder pour pclass** : préserve la hiérarchie sémantique (1ère classe > 2ème > 3ème) en une seule colonne au lieu de 2 avec OHE.

3.3 Résultats expérimentaux

3.3.1 Figure 6 — Comparaison des modèles par validation croisée




FIGURE 6 – Boxplots des scores de validation croisée (5-fold) pour les 3 modèles. Chaque boîte représente la distribution des 5 scores ; la valeur centrale est annotée.

Analyse critique des résultats

La Figure 6 présente les distributions des scores de validation croisée pour les trois modèles, révélant des comportements distincts :

Régression Logistique (CV = 0.798, std = 0.020) : la boîte la plus étroite des trois, indiquant la meilleure **stabilité**. L'écart-type de 0.020 est le plus faible, ce qui signifie que le modèle produit des performances cohérentes indépendamment du découpage en folds. Les modèles linéaires régularisés (régularisation L2 par défaut) généralisent bien sur des datasets de petite taille.

Random Forest (CV = 0.792, std = 0.036) : performance légèrement inférieure à la RL en CV, mais avec une variance plus élevée. La boîte plus large indique que les performances varient davantage selon le découpage. Cependant, le RF affiche le **meilleur test accuracy** (0.810), montrant que sa capacité à capturer les non-linéarités l'avantage sur le jeu de test.

Gradient Boosting (CV = 0.822, std = 0.038) : le meilleur score de validation croisée mais aussi la plus grande variabilité (std = 0.038). Les grandes moustaches et la boîte étendue signalent un risque d'overfitting : le GB s'adapte très finement aux données d'entraînement, ce qui se traduit par de bonnes performances en CV mais un test accuracy inférieur (0.799). Sur un petit dataset de 891 exemples, le GB sans régularisation agressive est susceptible de mémoriser du bruit.

Interprétation globale : tous les modèles dépassent le seuil de 0.80 en termes de score central, confirmant que la chaîne de prétraitement est efficace. La variabilité

élevée du GB (par rapport à la RL) illustre la tension entre complexité du modèle et stabilité de généralisation.

TABLE 4 – Résultats complets de l’évaluation — Partie I

Modèle	CV Accuracy	$\pm$ Std	Test Accuracy	AUC-ROC
Régression Logistique	0.7978	0.0204	0.8045	0.8437
Random Forest (base)	0.7922	0.0356	0.8101	0.8354
Gradient Boosting	0.8218	0.0385	0.7989	0.8179
RF Optimisé (GridSearchCV)	0.8302	0.0492	0.7989	0.8412

3.3.2 Figure 7— Évaluation finale du modèle optimisé




FIGURE 7 – Évaluation du Random Forest optimisé : matrice de confusion (gauche), courbe ROC (centre), importance des features (droite).

Analyse critique des résultats

La Figure 7 présente trois compléments d’évaluation du Random Forest optimisé par GridSearchCV.

Matrice de confusion (gauche). La matrice révèle la nature des erreurs du modèle sur les 179 exemples du test set :

- **Vrais négatifs (TN, en haut à gauche)** : le modèle prédit correctement “décédé” pour la grande majorité des passagers réellement décédés. Le taux de bonnes prédictions pour la classe 0 (précision $\approx 83\%$) est satisfaisant.
- **Vrais positifs (TP, en bas à droite)** : parmi les survivants réels, le modèle en identifie correctement la majorité, avec un rappel d’environ 71%.

-
- **Faux négatifs (FN, en bas à gauche)** : des survivants réels sont classifiés comme décédés. C'est le type d'erreur le plus coûteux dans ce contexte (manquer un survivant).
 - **Faux positifs (FP, en haut à droite)** : des passagers décédés sont classifiés comme survivants — moins grave statistiquement mais illustrant les cas ambigus.

L'asymétrie entre les performances sur les deux classes (meilleure précision sur la classe 0) s'explique par le déséquilibre modéré du dataset (62% vs 38%).

Courbe ROC (centre). La courbe ROC trace le taux de vrais positifs (TPR = rappel) en fonction du taux de faux positifs (FPR) pour tous les seuils de décision possibles entre 0 et 1. L'AUC (aire sous la courbe) de **0.841** indique que le modèle discrimine correctement les deux classes dans 84.1% des cas, quelle que soit la valeur de seuil choisie. La courbe bleue est nettement au-dessus de la diagonale rouge (classifieur aléatoire, $AUC = 0.5$), confirmant la valeur ajoutée du modèle. La zone ombrée sous la courbe visualise cette aire.

Importance des features (droite). Les barres représentent la contribution relative de chaque feature à la réduction d'impureté (critère de Gini) à travers les 50 arbres du RF optimisé :

- **sex_male** ($\approx 40\%$) : de loin la variable la plus discriminante, confirmant l'analyse descriptive de la Figure 2. Le sexe est le meilleur prédicteur de survie.
- **fare** ($\approx 20\%$) : le tarif du billet est un proxy du statut socio-économique — les passagers de 1ère classe (tarifs élevés) avaient un meilleur accès aux canots de sauvetage.
- **pclass** ($\approx 15\%$) et **age** ($\approx 12\%$) : contributions significatives mais secondaires.
- **sibsp, parch, ports d'embarquement** : contributions marginales.

4 Partie II — Données textuelles : 20 Newsgroups

4.1 Représentations vectorielles

Définition

TF-IDF (Term Frequency – Inverse Document Frequency) pondère chaque mot par sa fréquence dans le document et sa rareté dans le corpus :

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \frac{N}{\text{df}(t)}$$

Un mot fréquent partout (“the”) a un IDF ≈ 0 . Un mot spécifique à une catégorie (“orbit”) a un IDF élevé.

4.1.1 Pourquoi les matrices textuelles sont creuses

Avec un vocabulaire de 10 000 mots et des articles utilisant en moyenne 200 mots distincts, 9 800 entrées de chaque vecteur sont nulles. La densité est de 2%. Ces matrices sont stockées en format *sparse* (CSR) pour économiser la RAM.

Point de vigilance

On ne peut pas appliquer de centrage (soustraction de la moyenne) sur une matrice *sparse* : les zéros deviendraient $-\mu \neq 0$, rendant la matrice dense et saturant potentiellement la RAM.

4.2 Résultats expérimentaux

TABLE 5 – Comparaison des pipelines textuels (Test Accuracy)

Pipeline	Vectorisation + Modèle	Test Accuracy	Statut
A	CountVect (1g) + NaiveBayes	0.8912	Baseline
B	TF-IDF (1g) + NaiveBayes	0.8925	Amélioration attendue
C	TF-IDF (1-2g) + LogReg	0.8731	Paradoxe — voir analyse

4.2.1 Figure 8 — Matrice de confusion et comparaison des pipelines




FIGURE 8 — Gauche : matrice de confusion du pipeline B (TF-IDF + NaiveBayes). Droite : comparaison des 3 pipelines textuels.

Analyse critique des résultats

Matrice de confusion (gauche) — Pipeline B : TF-IDF + NaiveBayes.

La matrice montre les prédictions sur les 4 catégories du test set. L'analyse révèle plusieurs observations importantes :

Performances par diagonale : les 4 cases diagonales (prédiction correcte) dominent largement. Chaque catégorie est correctement classifiée pour environ 89-90% de ses exemples, ce qui est excellent pour 4 catégories avec du texte bruité.

Erreurs inter-catégories : les quelques erreurs observées se concentrent entre catégories thématiquement proches. Des confusions mineures entre `comp.graphics` et `sci.space` peuvent s'expliquer par un vocabulaire technique partagé (images satellites, modélisations). Les catégories `rec.sport.baseball` et `talk.politics.guns` sont mieux séparées car leurs vocabulaires sont très spécifiques.

Symétrie des erreurs : les erreurs sont globalement symétriques entre les catégories, ce qui indique que le modèle ne favorise pas arbitrairement une classe.

Comparaison des pipelines (droite). Le graphique en barres confirme les résultats du Tableau 5. Pipeline A (CountVect + NB) = 0.8912 constitue une baseline solide. Pipeline B (TF-IDF + NB) = 0.8925 apporte une légère amélioration attendue : l'IDF pondère mieux les termes discriminants. Pipeline C (TF-IDF bigrammes + LogReg) = 0.8731 présente un paradoxe expliqué ci-dessous.

Analyse du paradoxe Pipeline C. L'ajout de bigrammes avec `ngram_range=(1,2)` génère un espace de features potentiel de 50 000 à 100 000 combinaisons, alors que le budget `max_features=10 000` est partagé entre unigrammes et bigrammes. Des bigrammes fréquents mais peu informatifs ("said that", "in the") occupent des slots au détriment des meilleurs unigrammes thématiques

(“baseball”, “nasa”, “firearm”). Ce n’est pas un bug : augmenter `max_features` à 50 000 inverserait cette tendance.

4.2.2 Figure 9 — Mots discriminants par catégorie




FIGURE 9 – Top 15 mots les plus discriminants par catégorie selon les coefficients de la Régression Logistique (Pipeline C, TF-IDF bigrammes). Un coefficient élevé indique que ce mot pousse fortement vers la prédiction de la catégorie correspondante.

Analyse critique des résultats

La Figure 9 visualise l’interprétabilité intrinsèque de la Régression Logistique : les coefficients du modèle linéaire quantifient directement l’importance de chaque terme pour chaque catégorie.

Catégorie `rec.sport.baseball`. Le terme *baseball* domine avec un coefficient de ≈ 2.7 , seul mot dépassant 2.5. Il est suivi de termes génériques du sport collectif (*game*, *team*, *year*) et de références spécifiques au baseball américain (*cubs*, *braves*, *stadium*, *runs*). Les coefficients restent entre 1.4 et 2.2, indiquant un vocabulaire discriminant mais moins exclusif que pour les autres catégories.

Catégorie `sci.space`. *space* présente le coefficient le plus élevé de toute la figure (≈ 4.7), reflétant son caractère quasi-exclusif à cette catégorie. *orbit*, *nasa*, *moon*, *launch* suivent entre 1.8 et 2.0. Ce coefficient particulièrement élevé s’explique par la rareté du mot *space* dans les trois autres catégories (baseball, armes, graphisme).

Catégorie talk.politics.guns. *gun* et *guns* dominent avec des coefficients de ≈ 3.5 et ≈ 2.6 . Le champ lexical de la violence et de la régulation (*weapons, fbi, law, firearms, police, batf, killed, nra*) est bien représenté, reflétant le débat américain sur le contrôle des armes. L'absence de bigrammes comme *second amendment* parmi les 15 premiers coefficients s'explique par la contrainte `max_features=10 000` partagée entre unigrammes et bigrammes (voir analyse du paradoxe ci-dessous).

Catégorie comp.graphics. *graphics* domine à ≈ 3.4 , suivi de *image* (≈ 2.2). Le reste du vocabulaire (*file, files, 3d, computer, windows, code, format*) reflète les discussions techniques des forums informatiques. L'absence de termes attendus comme *jpeg, pixel* ou *rgb* s'explique par le même budget `max_features` insuffisant qui est à l'origine du paradoxe du Pipeline C : ces tokens spécifiques ont été évincés par des tokens plus fréquents mais moins discriminants.

Conclusion sur l'interprétabilité. La cohérence globale entre les termes identifiés et les thématiques attendues confirme le bon fonctionnement du modèle. Cette analyse par coefficients est impossible avec un Random Forest (importance globale, non différenciée par classe) ou un réseau de neurones (représentations distribuées non interprétables directement) — c'est l'avantage décisif de la Régression Logistique en NLP.

5 Discussion critique

5.1 Apports méthodologiques

Architecture Pipeline + ColumnTransformer. Ces deux outils résolvent deux problèmes distincts. Le `ColumnTransformer` résout l'hétérogénéité des types de variables : il est impossible d'appliquer un `StandardScaler` à une colonne de texte. Le `Pipeline` résout le data leakage : le prétraitement est toujours cohérent entre train et test, y compris lors de la validation croisée.

Valeur des résultats contre-intuitifs. Les deux paradoxes observés (GB overfittant sur 891 exemples, bigrammes moins performants avec un budget insuffisant) sont plus instructifs qu'une amélioration monotone : ils illustrent des phénomènes fondamentaux du Machine Learning.

5.2 Limites

- **Taille du dataset Titanic** : 891 exemples induisent une variance d'estimation élevée. Les résultats sont sensibles au `random_state` du split.
- **TF-IDF et sémantique** : “orbit” et “satellite” sont deux tokens distincts pour TF-IDF malgré leur proximité sémantique. Les embeddings (Word2Vec, BERT) surmonteraient cette limite.
- **Absence de lemmatisation** : “running” et “run” comptent comme deux mots différents, augmentant inutilement la dimensionnalité.
- **Budget max_features** insuffisant pour les bigrammes dans la Partie II.

5.3 Prolongements possibles

1. **Feature engineering (Partie I)** : extraire le titre social du nom (*Mr.*, *Mrs.*, *Dr.*, *Master*), créer une variable `family_size = sibsp + parch + 1`.
2. **Correction du paradoxe bigrammes** : augmenter `max_features` à 50 000 ou utiliser `sublinear_tf=True`.
3. **Embeddings (Partie II)** : Word2Vec, GloVe, ou BERT pour capturer la sémantique.
4. **Interprétabilité avancée** : SHAP (*SHapley Additive exPlanations*) pour les contributions individuelles du Random Forest.
5. **Gestion du déséquilibre** : tester `class_weight='balanced'` ou SMOTE.

6 Conclusion

Ce projet a démontré la construction et l'évaluation de deux chaînes complètes de traitement de données, depuis l'inspection initiale jusqu'à l'analyse critique des sorties.

Partie I. L'inspection rigoureuse du dataset Titanic a identifié une fuite directe (**alive**), une colonne trop incomplète (**deck**), et cinq colonnes redondantes. Le **ColumnTransformer** a appliqué des stratégies adaptées à chaque type de variable. Parmi les modèles comparés, la Régression Logistique offre le meilleur équilibre stabilité/performance sur ce petit dataset (test accuracy 0.805, AUC-ROC 0.844).

Partie II. La comparaison de trois représentations textuelles a mis en évidence l'apport de l'IDF et le paradoxe des bigrammes avec un budget de features insuffisant. L'inspection des coefficients de la Régression Logistique a validé la cohérence sémantique du modèle.

Réflexion finale. La qualité d'une chaîne de traitement repose sur la rigueur méthodologique : compréhension des données, justification des choix, prévention du data leakage, et interprétation honnête des résultats — y compris les résultats inattendus.

6 Références

- [1] Pedregosa, F. et al. (2011). *Scikit-learn : Machine Learning in Python*. JMLR, 12, 2825–2830.
- [2] McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proc. 9th Python in Science Conf.
- [3] Kaggle. *Titanic : Machine Learning from Disaster*. <https://www.kaggle.com/c/titanic>
- [4] Lang, K. (1995). *NewsWeeder : Learning to Filter Netnews*. Proc. 12th ICML, 331–339.
- [5] Manning, C.D., Raghavan, P., Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge Univ. Press.
- [6] Bishop, C.M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [7] Salhi, I. (2025-2026). *Cours : Nettoyage et prétraitement des données*. EMSI.

A Annexe A — Liste des figures et leur signification

Figure	Fichier	Contenu
Fig. 1	fig1_missing_values.png	% NaN par colonne
Fig. 2	fig2_target_distribution.png	Distribution cible + par sexe
Fig. 3	fig3_numerical_distributions.png	Histogrammes + boxplots numériques
Fig. 5	fig4_correlation_matrix.png	Matrice de corrélation Pearson
Fig. 6	fig5_cv_comparison.png	Boxplots scores CV 5-fold
Fig. 7	fig6_model_evaluation.png	Confusion + ROC + feature importance
Fig. ??	fig7_final_comparison.png	Comparaison finale 3 métriques
Fig. 8	fig8_text_classification.png	Matrice confusion texte + pipeline bars
Fig. 9	fig9_top_words.png	Top mots discriminants (LogReg)

B Annexe B — Formules clés

Méthode	Formule	Cas d'usage
StandardScaler	$x' = \frac{x - \mu}{\sigma}$	Distribution approx. normale
MinMaxScaler	$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$	Bornes connues, sans outliers
RobustScaler	$x' = \frac{x - Q_2}{\text{IQR}}$	Nombreux outliers
TF-IDF	$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \log \frac{N}{\text{df}(t)}$	Classification textuelle
Accuracy	$\frac{TP + TN}{TP + TN + FP + FN}$	Classes équilibrées
AUC-ROC	Aire sous la courbe $\text{TPR} = f(\text{FPR})$	Classes déséquilibrées